

Detecção de comunidades em proteínas

Aluno: João Lucas Pontes Freitas

Data: 02/07/2026

1. Introdução

Este projeto aplica conceitos de redes complexas à análise de estruturas proteicas, de forma que cada estrutura foi representada por um grafo não direcionado e não ponderado. Os vértices representam resíduos de aminoácidos por meio da coordenada do átomo C α , e uma aresta é criada quando a distância entre dois C α é menor ou igual a 8 Å, o parâmetro de proximidade adotado na construção da rede.

O alvo principal é a estrutura 6B1T, referente ao adenovírus [2]. Como essa estrutura é grande, o pipeline foi testado primeiro na 1PKN [3], que possui tamanho menor e permite validar todo o fluxo com menor custo computacional. Para cada experimento, foram calculadas: a distribuição de graus, a centralidade de grau e a centralidade de autovetor. Além disso, as comunidades foram detectadas pelo algoritmo Louvain da biblioteca python-igraph.

No teste (1PKN) foram encontradas 5 comunidades, com modularidade 0,8139. Na 6B1T foram encontradas 13 comunidades, com modularidade 0,9333 e pureza ponderada de 0,9249 em relação às entidades anotadas. A validação mínima foi atendida: 439 dos 455 resíduos do penton ficaram em sua comunidade dominante, cuja pureza foi de aproximadamente 94,82%.

2. Dados e preparação

Os arquivos com as duas estruturas do RCSB Protein Data Bank foram obtidos no formato comprimido PDBx/mmCIF.gz. Embora o enunciado mencione o pacote PDB comprimido em tar.gz, foi utilizado o formato PDBx/mmCIF.gz disponibilizado pelo RCSB. Esse formato contém as coordenadas estruturais necessárias e fornece acesso estruturado às cadeias, aos resíduos e às entidades proteicas utilizadas na validação biológica.

O código verifica primeiro se o arquivo já está dentro do diretório de dados. Caso exista, ele é reutilizado; caso contrário, é baixado automaticamente dos endpoints do RCSB. Além disso, a análise de distância utiliza o primeiro modelo de coordenadas presente no arquivo. Para a 6B1T, a análise foi realizada sobre as coordenadas depositadas no arquivo PDBx/mmCIF, sem aplicação de transformações adicionais de montagem biológica.

3. Construção da rede

3.1 Parsing

A leitura dos arquivos PDBx/mmCIF foi realizada com a biblioteca Gemmi [6]. Para cada resíduo válido, o programa extrai:

- cadeia;
- entidade;
- número do resíduo;
- nome do resíduo;
- coordenadas tridimensionais do átomo C α .

O Gemmi realiza a leitura da estrutura atômica completa. Para a construção da rede, porém, o pipeline seleciona apenas o átomo C α de cada resíduo válido, pois cada resíduo é representado por um único vértice. Águas, íons, ligantes, resíduos que não são aminoácidos e resíduos sem C α são ignorados.

3.2 Vértices

Cada vértice representa um resíduo de aminoácido. Sua posição é dada pelas coordenadas do átomo C α . Essa representação reduz a quantidade de dados em comparação com uma rede construída com todos os átomos e mantém uma posição representativa para cada resíduo. Águas, íons, ligantes e demais componentes que não pertencem ao modelo de resíduos foram excluídos durante o parsing.

3.3 Arestas e limiar de 8 Å

Dois vértices são conectados quando:

$$\text{distância}(\text{C}\alpha_i, \text{C}\alpha_j) \leq 8 \text{ Å}$$

Å é uma unidade de medida de comprimento chamada Ångström, de forma que um ångström corresponde a 10^{-10} metros. Neste projeto, o valor de 8 Å funciona como um parâmetro de proximidade: se dois C α estão separados por no máximo essa distância, considera-se que existe um contato entre os resíduos. O limiar de 8 Å foi adotado com base em redes de resíduos descritas na literatura [1], sendo válido ressaltar que o mesmo valor foi usado na 1PKN e na 6B1T.

O grafo construído é:

- **simples:** não possui laços nem arestas duplicadas;
- **não direcionado:** se existe uma aresta entre i e j, a mesma relação vale de j para i ;

- **não ponderado:** todas as arestas representam apenas a existência de um contato. A distância exata entre os resíduos não é utilizada como peso.

Durante o desenvolvimento, também foram avaliados outros pontos de corte como os valores de 6 Å e 10 Å. Com 6 Å, a rede ficou mais esparsa, já que menos pares de resíduos satisfaziam o critério de proximidade. Com 10 Å, a quantidade de arestas aumentou e a rede ficou mais densa, incluindo contatos mais distantes. O valor de 8 Å apresentou um equilíbrio entre preservar contatos locais e evitar densidade excessiva, além de ser compatível com valores utilizados na literatura [1].

3.4 Construção do Grafo

A busca dos pares de resíduos dentro do limiar estabelecido foi realizada através do método `scipy.spatial.cKDTree.query_pairs` [7,8]. Essa estrutura evita calcular e armazenar uma matriz completa de distâncias $N \times N$. Isso é importante para a 6B1T, que possui mais de doze mil vértices.

A biblioteca `python-igraph` foi escolhida em vez de `NetworkX` principalmente por eficiência computacional, uma vez que o núcleo do `igraph` é implementado em C, o que o torna adequado para operações em grafos maiores. Essa escolha é relevante porque a rede da 6B1T possui 12.544 vértices e 66.809 arestas. O `igraph` também fornece diretamente as rotinas usadas neste projeto para centralidade, modularidade e Louvain [5], assim como o `NetworkX` que usamos em sala.

4. Análise da rede

4.1 Distribuição de graus

O grau de um vértice é o número de contatos diretos do resíduo correspondente.

Foram calculados:

- grau mínimo;
- grau médio;
- grau máximo;
- distribuição de frequências dos graus.

4.2 Centralidade de grau

A centralidade de grau foi representada pelo próprio número de contatos de cada resíduo. Quanto maior o valor, maior a quantidade de vizinhos diretos.

4.3 Centralidade de autovetor

A centralidade de autovetor atribui valores maiores a vértices conectados a outros vértices também centrais:

$$x_i = (1 / \lambda) \sum_j A_{ij} x_j$$

Essa medida complementa o grau, pois considera não apenas a quantidade de conexões, mas também a importância dos vizinhos.

5. Detecção de comunidades

Foi utilizado o algoritmo Louvain, uma heurística gulosa de detecção de comunidades baseada na otimização da modularidade [4].

Os parâmetros finais foram:

Estrutura	Cutoff	Resolução	Semente
1PKN	8 Å	0,5	42
6B1T	8 Å	0,3	42

Durante o desenvolvimento, o cutoff também foi testado na 1PKN com valores de 6 Å e 10 Å. Com 6 Å, a rede apresentou 1.428 arestas, grau médio de 5,56 e 12 comunidades, mostrando uma estrutura mais esparsa que a obtida com 8 Å. Com 10 Å, foram geradas 4.845 arestas e grau médio de 18,85, produzindo uma rede consideravelmente mais densa. O cutoff de 8 Å resultou em uma condição intermediária, com 2.627 arestas, grau médio de 10,22 e 5 comunidades. Por esse equilíbrio e por sua compatibilidade com valores utilizados na literatura [1], 8 Å foi mantido como parâmetro final.

A resolução 0,3 foi adotada por apresentar um equilíbrio melhor entre quantidade de comunidades e correspondência com as entidades anotadas. Com esse valor, foram encontradas 13 comunidades, modularidade de 0,9333 e pureza ponderada de 0,9249. A semente 42 foi fixada para tornar a execução reprodutível.

6. Estratégia de teste

Todo o pipeline foi executado primeiro na 1PKN. Essa execução validou:

- download e reutilização do arquivo estrutural;
- leitura do mmCIF;
- extração dos resíduos C α ;
- construção do grafo;
- cálculo dos graus;
- cálculo das centralidades;
- execução do Louvain;
- geração dos arquivos de resultados;
- geração das figuras.


Depois dessa validação, o mesmo fluxo foi aplicado à 6B1T.

7. Resultados da 1PKN

7.1 Resumo do grafo

Propriedade	Resultado
Vértices	514
Arestas	2.627
Grau mínimo	2
Grau médio	10,22
Grau máximo	19

O grau médio indica que cada resíduo possui aproximadamente dez contatos quando utilizamos um limiar de 8 Å. Além disso, a distribuição concentra a maior parte dos resíduos no centro do gráfico, enquanto poucos resíduos apresentam valores muito baixos ou próximos do máximo. Isso indica que a maioria dos resíduos possui uma quantidade semelhante de vizinhos próximos.




Legenda: *Distribuição de graus da rede da 1PKN.*


7.2 Centralidades

O maior grau foi observado no resíduo THR 364 da cadeia A, com valor 19. A maior centralidade de autovetor ocorreu no resíduo ILE 358 da cadeia A. Na visualização tridimensional, os maiores valores de grau e autovetor aparecem principalmente em regiões mais internas e densamente ocupadas da estrutura, enquanto regiões periféricas apresentam valores menores.

1PKN — Centralidade de grau
cutoff=8.0 Å



Legenda: *Centralidade de grau na estrutura 1PKN.*




Legenda: *Centralidade de autovetor na estrutura 1PKN.*

7.3 Comunidades

Métrica	Resultado
Comunidades	5
Modularidade	0,8139

A modularidade indica que a rede foi dividida em grupos com maior concentração de conexões internas.

1PKN — comunidades Louvain
5 comunidades, modularidade=0.8139, resolução=0.5, cutoff=8.0 Å



Legenda: *Comunidades Louvain detectadas na 1PKN.*


8. Resultados da 6B1T

8.1 Resumo do grafo

Propriedade	Resultado
Vértices	12.544
Arestas	66.809

Propriedade	Resultado
Grau mínimo	2
Grau médio	10,65
Grau máximo	20

Os graus médios da 1PKN e da 6B1T foram próximos, apesar da diferença no número de vértices. Isso é compatível com o uso de um limiar bom em representar contatos próximos. A distribuição da 6B1T também se concentra em graus intermediários e apresenta poucos resíduos nos extremos.




Legenda: *Distribuição de graus da rede da 6B1T.*

8.2 Centralidades


O maior grau foi observado no resíduo GLY 839 da cadeia A, com valor 20. A maior centralidade de autovetor ocorreu no resíduo PRO 173 da cadeia I. Os dois resíduos pertencem ao hexon, que corresponde à maior parte do modelo analisado. Na 6B1T, a centralidade de grau aparece distribuída por regiões densas da estrutura, enquanto a centralidade de autovetor se concentra mais fortemente em uma região específica. Isso mostra a diferença entre possuir muitos contatos diretos e estar conectado a outros vértices também centrais.

6B1T — Centralidade de grau
cutoff=8.0 Å



Legenda: *Centralidade de grau na estrutura 6B1T.*

6B1T — Centralidade de autovetor
cutoff=8.0 Å




Legenda: *Centralidade de autovetor na estrutura 6B1T.*

8.3 Comunidades

Métrica	Resultado
Resolução	0,3
Semente	42
Comunidades	13
Modularidade	0,9333
Pureza ponderada	0,9249

6B1T — comunidades Louvain
13 comunidades, modularidade=0.9333, resolução=0.3, cutoff=8.0 Å



Legenda: *Comunidades Louvain detectadas na 6B1T.*

A visualização tridimensional mostra grupos espacialmente compactos. A identificação biológica desses grupos foi feita comparando a comunidade de cada resíduo com a entidade anotada no arquivo mmCIF.

9. Validação biológica da 6B1T

Foram consideradas oito entidades anotadas:

1. hexon;
2. penton;
3. proteína IIIa;
4. proteína VIII;
5. proteína IX;

6. pré-proteína VI;
7. proteína VII;
8. outra ocorrência da pré-proteína VI.

A comparação foi feita por meio de:

- matriz de contingência entre entidades e comunidades;
- cobertura de cada entidade;
- pureza de cada comunidade;
- pureza ponderada.

9.1 Resultado quantitativo

Avaliação	Resultado
Entidades anotadas	8
Comunidades detectadas	13
Pureza ponderada	92,49%
Resíduos do penton na comunidade dominante	439 de 455
Cobertura do penton	96,48%
Pureza da comunidade dominante do penton	94,82%

A pureza ponderada indica que aproximadamente 92,49% dos resíduos pertencem à entidade dominante da comunidade em que foram classificados.

9.2 Interpretação

O penton ficou concentrado principalmente em uma comunidade: 439 dos seus 455 resíduos ficaram no mesmo grupo. Essa comunidade contém 463 resíduos no total, dos quais 439 pertencem ao penton. O hexon foi distribuído entre várias comunidades. Isso ocorre porque o Louvain identifica grupos de conectividade do grafo, e não força uma correspondência de uma comunidade para cada entidade anotada.

A separação mínima esperada entre penton e hexon foi atendida. A correspondência com todas as entidades foi parcial, pois foram encontradas 13 comunidades para 8 entidades, com maior fragmentação do hexon.

10. Conclusão

O modelo adotado permitiu executar as mesmas etapas na proteína de teste e no alvo principal. Na 1PKN, o pipeline produziu um grafo de 514 vértices e identificou 5 comunidades. Já na 6B1T, o mesmo processo produziu um grafo de 12.544 vértices e 13 comunidades.

As centralidades apontaram os resíduos mais conectados e os resíduos inseridos nas regiões mais centrais da rede. Na 6B1T, os maiores valores ocorreram no hexon. A modularidade foi elevada nas duas estruturas. Na validação biológica, o penton foi separado com alta cobertura e pureza. O hexon foi dividido em vários grupos, mostrando que uma comunidade do grafo não corresponde obrigatoriamente a uma única entidade anotada.

11. Uso de inteligência artificial

Foi utilizado o ChatGPT como apoio durante o desenvolvimento.

- **Modelo:** GPT-5.5 Thinking.
- **Temperatura:** não informada pela interface.
- **Escopo:** Ajuda utilizada especialmente na geração de códigos utilizando as bibliotecas de código encontradas durante a pesquisa para o PARSE e na geração de códigos de VISUALIZAÇÃO. Validação do que o encontrado na pesquisa era algo funcional.
- **Prompts:** Solicitações iterativas para corrigir erros, melhorar grafos e revisar os textos e descobertas das pesquisas.

A pesquisa por fontes que ajudaram a tomar as decisões em relação ao limiar e as bibliotecas, além da validação dos resultados foram todas feitas por mim.

12. Discussões com colegas

Não houve discussões, colaboração técnica ou compartilhamento de código com colegas durante o desenvolvimento deste projeto.

Referências

- [1] GRANT, W. P.; AHNERT, S. E. Modular decomposition of protein structure using community detection. *Journal of Complex Networks*, v. 7, n. 1, p. 101–113, 2019. DOI: [10.1093/comnet/cny014](https://doi.org/10.1093/comnet/cny014).
- [2] RCSB PROTEIN DATA BANK. 6B1T: *Improved cryoEM structure of human adenovirus type 5 with atomic details of minor proteins VI and VII*. PDB DOI: [10.2210/pdb6B1T/pdb](https://doi.org/10.2210/pdb6B1T/pdb).
- [3] RCSB PROTEIN DATA BANK. 1PKN: *Structure of rabbit muscle pyruvate kinase complexed with Mn²⁺, K⁺, and pyruvate*. PDB DOI: [10.2210/pdb1PKN/pdb](https://doi.org/10.2210/pdb1PKN/pdb).
- [4] BLONDEL, V. D.; GUILLAUME, J.-L.; LAMBIOTTE, R.; LEFEBVRE, E. Fast unfolding of communities in large networks. *Journal of Statistical Mechanics: Theory and Experiment*, v. 2008, n. 10, P10008, 2008. DOI: [10.1088/1742-5468/2008/10/P10008](https://doi.org/10.1088/1742-5468/2008/10/P10008).
- [5] CSÁRDI, G.; NEPUSZ, T. The igraph software package for complex network research. *InterJournal, Complex Systems*, n. 1695, 2006.
- [6] WOJDYR, M. GEMMI: A library for structural biology. *Journal of Open Source Software*, v. 7, n. 73, p. 4200, 2022. DOI: [10.21105/joss.04200](https://doi.org/10.21105/joss.04200).
- [7] VIRTANEN, P. et al. SciPy 1.0: fundamental algorithms for scientific computing in Python. *Nature Methods*, v. 17, p. 261–272, 2020. DOI: [10.1038/s41592-019-0686-2](https://doi.org/10.1038/s41592-019-0686-2).
- [8] SCIPY DEVELOPERS. `scipy.spatial.cKDTree.query_pairs`. *SciPy Reference Guide*. Disponível em: https://docs.scipy.org/doc/scipy/reference/generated/scipy.spatial.cKDTree.query_pairs.html.